

1. Visao Geral do Projeto

O Precificador 61 Moveis utiliza a API da Anthropic (Claude) para alimentar a assistente virtual Sofia, disponivel como chat widget na pagina publica. A Sofia responde duvidas de clientes sobre busca de imoveis, precificacao de mercado e dicas de anuncio, chamando ferramentas internas que consultam o banco de dados PostgreSQL da plataforma.

Stack de IA

Modelo utilizado:	claude-sonnet-4-6 (Claude Sonnet 4)
SDK Python:	anthropic >= 0.40.0
Endpoint:	POST /api/v1/chat (Flask back-end)
Sessoes:	In-memory por session_id (browser sessionStorage)
Historico maximo:	20 mensagens por sessao (_MAX_HISTORY = 20)
max_tokens por chamada:	1024 tokens (linhas 303 e 327 do chat_service.py)

Ferramentas (Function Calling) definidas

buscar_imoveis	Busca ate 5 imoveis por criterios (tipo, bairro, quartos, preco)
precificar_imovel	Avalia preco de mercado por tipo, bairro e oferta
dicas_anuncio	Gera dicas baseadas nos dados reais do mercado local

2. Anatomia de uma Chamada a API

Cada mensagem do usuario pode gerar 1 ou 2 chamadas a API (agentic loop):

Etapas	Input (tokens)	Output (tokens)	Observacao
1a chamada (sem tool use)	1.000 - 2.000	200 - 400	Resposta direta
1a chamada (com tool use)	1.200 - 2.500	150 - 250	Retorna JSON da tool
Resultado da tool injetado	300 - 1.000	-	Dados do BD em JSON
2a chamada (resposta final)	2.000 - 4.500	300 - 600	Texto para o usuario

System prompt fixo: ~430 tokens | Definicao das 3 tools: ~600 tokens
Overhead fixo por chamada: ~1.030 tokens de entrada (repetido em TODAS as chamadas).
Quando a Sofia usa uma ferramenta, o custo medio de entrada por troca de mensagem sobe de ~1.500 para ~4.000 tokens.

3. Tabela de Precos - Claude Sonnet 4 (Anthropic, 2025)

Tipo de Token	Preco (por 1M tokens)	Equivalente por 1K tokens
Input (sem cache)	US\$ 3,00	US\$ 0,003
Output	US\$ 15,00	US\$ 0,015
Cache Write (escrita cache)	US\$ 3,75	US\$ 0,00375
Cache Read (leitura cache)	US\$ 0,30	US\$ 0,0003

Nota: Output e 5x mais caro que o Input. Respostas mais curtas tem grande impacto no custo.

4. Estimativas de Custo Mensal - 150 usuarios

Premissas: ~70% das trocas de mensagens acionam ferramentas (2 chamadas a API). 30% sao respostas diretas (1 chamada). Cambio estimado: US\$ 1 = R\$ 5,80.

61 Imoveis - Relatorio de Custo: API Claude (Anthropic)

BAIXO	Cenario Conservador - 1-2 sessoes, 3 trocas/sessao			
Metrica	Sessoes	Trocas	Tokens In	Tokens Out
150 usuarios x 1,5 sess x 3 trocas	225	675	1,82M	337K

Custo estimado (USD): US\$ 6,50 a US\$ 11,00 / mes

Custo estimado (BRL): R\$ 37 a R\$ 64 / mes

MEDIO	Cenario Moderado - 2 sessoes, 5 trocas/sessao (cenario mais provavel)			
Metrica	Sessoes	Trocas	Tokens In	Tokens Out
150 usuarios x 2 sess x 5 trocas	300	1.500	5,01M	900K

Custo estimado (USD): US\$ 25,00 a US\$ 30,00 / mes

Custo estimado (BRL): R\$ 145 a R\$ 174 / mes

ALTO		Cenario Intenso - 4 sessoes, 8 trocas/sessao (historico longo)			
Metrica		Sessoes	Trocas	Tokens In	Tokens Out
150 usuarios x 4 sess x 8 trocas		600	4.800	19,7M	3,36M

Custo estimado (USD): US\$ 95,00 a US\$ 115,00 / mes

Custo estimado (BRL): R\$ 550 a R\$ 667 / mes

5. Estrategias para Limitar e Reduzir o Custo

5.1 Prompt Caching (MAIOR IMPACTO - recomendado AGORA)

O system prompt (~430 tok) + definicao das 3 tools (~600 tok) = ~1.030 tokens se repetem em TODAS as chamadas. Com prompt caching da Anthropic, esses tokens sao escritos uma vez (US\$ 3,75/M) e relidos a US\$ 0,30/M = 90% mais barato. Como implementar: adicionar cache_control: {type: 'ephemeral'} ao ultimo bloco do system prompt e ao ultimo tool da lista (chat_service.py). Estimativa de economia: 25-40% do custo total.

5.2 Reduzir o Historico Maximo (_MAX_HISTORY)

Atualmente definido como 20 mensagens. Cada mensagem extra aumenta tokens de entrada em todas as chamadas seguintes da mesma sessao. Reduzir para 10 mensagens mantem contexto suficiente e pode reduzir o custo de sessoes longas em ate 50%. Editar: back-end/app/services/chat_service.py, linha 293.

5.3 Reduzir max_tokens de 1024 para 512

As respostas da Sofia raramente ultrapassam 400 tokens. Reduzir para 512 nao afeta a qualidade mas evita respostas excessivamente longas. Como Output custa 5x mais que Input, isso tem impacto relevante. Editar: chat_service.py, linhas 303 e 327.

5.4 Rate Limiting por Sessao / IP

Implementar limite de mensagens por sessao (ex: max 15 mensagens) e por IP (ex: 50 mensagens/dia). Protege contra usuarios que deixam a janela aberta por horas ou contra abuso. Pode ser feito com Flask-Limiter (compativel com o stack atual).

5.5 Budget Alert via Anthropic Console

Configurar alertas de gasto em console.anthropic.com. Definir limite mensal (ex: US\$ 50) e receber e-mail ao atingir 80%. Nao reduz o custo mas evita surpresas na fatura. Criar API Key especifica para producao com limite separado.

5.6 Rotear perguntas simples para Claude Haiku (20x mais barato)

Claude Haiku 4.5 custa ~20x menos que o Sonnet. Saudacoes, perguntas simples e respostas sem ferramentas nao precisam do Sonnet. Um classificador leve roteia para Haiku quando nao houver necessidade de tools. Estimativa de economia: 15-30% dependendo do mix de perguntas.

5.7 Migrar sessoes para Redis (TTL automatico)

O armazenamento in-memory atual nao tem TTL: sessoes crescem indefinidamente ate o servidor reiniciar. Redis permite expirar sessoes apos 30 min de inatividade, limitando o historico acumulado e tokens enviados em cada chamada.

6. Plano de Acao Priorizado

#	Acao	Esforco	Economia Est.	Prioridade
1	Implementar Prompt Caching	Baixo (2h)	25-40%	ALTA
2	Reduzir _MAX_HISTORY de 20 para 10	Minimo (5min)	10-20%	ALTA
3	Reduzir max_tokens de 1024 para 512	Minimo (5min)	5-10%	ALTA
4	Rate Limiting com Flask-Limiter	Medio (1 dia)	Protecao abuso	MEDIA
5	Budget Alert no Console Anthropic	Minimo (10min)	Controle fatura	MEDIA
6	Rotear perguntas simples para Haiku	Alto (2 dias)	15-30%	BAIXA

7	Migrar sessoes para Redis	Alto (2 dias)	Estabilidade	BAIXA
---	---------------------------	---------------	--------------	-------

7. Resumo Executivo

Custo mais provavel (cenario medio, sem otimizacao):	US\$ 25-30 / mes = R\$ 145-174 / mes
Com Prompt Caching ativado:	US\$ 15-20 / mes = R\$ 87-116 / mes
Com Caching + historico reduzido para 10 msgs:	US\$ 10-15 / mes = R\$ 58-87 / mes
Cenario pessimista (alto uso, sem otimizacao):	US\$ 95-115 / mes = R\$ 550-667 / mes
Cenario pessimista com todas as otimizacoes:	US\$ 40-55 / mes = R\$ 232-319 / mes

Recomendacao imediata: implementar Prompt Caching, reduzir _MAX_HISTORY para 10 e max_tokens para 512. Essas tres mudancas somam ~50% de reducao de custo com menos de 30 minutos de trabalho e zero impacto na experiencia do usuario.